МГТУ им. Н. Э. Баумана, кафедра ИУ5 курс "Технология машинного обучения"

Лабораторная работа №4

«Подготовка обучающей и тестовой выборки, кроссвалидация и подбор гиперпараметров на примере метода ближайших соседей»

выполнил:

Нагдимаев И.И.

Группа: ИУ5-65Б

ПРОВЕРИЛ:

Гапанюк Ю.Е.

Цель лабораторной работы: изучение сложных способов подготовки выборки и подбора гиперпараметров на примере метода ближайших соседей.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 3. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью подходящих для задачи метрик.
- 4. Постройте модель и оцените качество модели с использованием кросс-валидации.
- 5. Произведите подбор гиперпараметра К с использованием GridSearchCV и кроссвалидации.

Выполненная работа

```
In [1]: import pandas as pd
       import numpy as np
        import os
        from sklearn.model selection import train test split
        from sklearn.datasets import make moons
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.metrics import accuracy score
        from sklearn.model_selection import KFold, cross_val_score
        from sklearn.model_selection import GridSearchCV
        # to make this notebook's output stable across runs
        np.random.seed(42)
        # To plot pretty figures
        %matplotlib inline
        import matplotlib as mpl
        import matplotlib.pyplot as plt
In [2]: GT PATH = os.path.join('dataset')
        def fetch gt path(gt path=GT PATH):
          os.makedirs(gt_path, exist_ok=True)
        fetch_gt_path()
In [3]: def load_data_(data, data_path=GT_PATH):
           csv path = os.path.join(data path, data)
           return pd.read_csv(csv_path)
```

Dataset

KneighborsClassifier

Критерий качества

```
In [8]: y_pred = k_neigh.predict(X_test)
accuracy_score(y_test, y_pred)

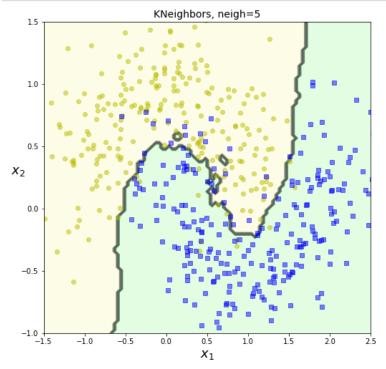
Out[8]: 0.9

In [9]: from matplotlib.colors import ListedColormap

def plot_decision_boundary(clf, X, y, axes=[-1.5, 2.5, -1, 1.5], alpha=0.5, contour=True):
    xls = np.linspace(axes[0], axes[1], 100)
    x2s = np.linspace(axes[2], axes[3], 100)
    x1, x2 = np.meshgrid(x1s, x2s)
    X_new = np.c_[x1.ravel(), x2.ravel()]
    y_pred = clf.predict(X_new).reshape(x1.shape)
    custom_cmap = ListedColormap(['#fafab0', '#9898ff', '#a0faa0'])
    plt.contour(x1, x2, y_pred, alpha=0.3, cmap=custom_cmap)
    if contour:
        custom_cmap2 = ListedColormap(['#7d7d58', '#4c4c7f', '#507d50'])
        plt.contour(x1, x2, y_pred, cmap=custom_cmap2, alpha=0.8)
        plt.plot(X[:, 0][y==0], X[:, 1][y==0], 'yo', alpha=alpha)
        plt.plot(X[:, 0][y==1], X[:, 1][y==1], 'bs', alpha=alpha)
        plt.axis(axes)
        plt.xlabel(r"Sx_15", fontsize=18)
        plt.ylabel(r"Sx_28", fontsize=18, rotation=0)
```

Рисунок

```
In [10]: plt.figure(figsize=(18, 8))
   plt.subplot(121)
   plot_decision_boundary(k_neigh, X, y)
   plt.title('KNeighbors, neigh=5', fontsize=14)
   plt.show()
```



```
In [11]: kf = KFold(n_splits=5, shuffle=True, random_state=42)
In [12]:
    cvs = cross_val_score(k_neigh, X, y, cv=kf, scoring='accuracy')
    cvs.mean()
```

Out[12]: 0.9099999999999999

Cross validation

```
In [13]: max mean = -1
         start_time = datetime.datetime.now()
         for i in range(1, 20, 2):
           clf = KNeighborsClassifier(n_jobs=-1, n_neighbors=i)
            cvs = cross_val_score(clf, X, y, cv=kf, scoring='accuracy')
            mean = cvs.mean()
            print(str(i) + ": " + str(mean))
            if mean > max_mean:
               max_mean = mean
max_n = i
         print("Time elapse: ", datetime.datetime.now() - start_time)
        print(max_n, max_mean)
        1: 0.858
         3: 0.9040000000000001
         5: 0.90999999999999
         7: 0.922
         9: 0.92000000000000002
         11: 0.919999999999999
         13: 0.921999999999999
         15: 0.917999999999999
         17: 0.911999999999999
         19: 0.908
         Time elapse: 0:00:00.812104
         7 0.922
```

При 7 соседях самая лучшая модель с точностью 0.922

```
In [14]: k_best_n = KNeighborsClassifier(n_jobs=-1, n_neighbors=7)
    k_best_n.fit(X_train, y_train)
    y_pred = k_best_n.predict(X_test)
    accuracy_score(y_test, y_pred)
```

Out[14]: 0.91333333333333333

При 7 соседях самая лучшая модель с точностью 0.922

```
In [14]: k_best_n = KNeighborsClassifier(n_jobs=-1, n_neighbors=7)
           k_best_n.fit(X_train, y_train)
           y_pred = k_best_n.predict(X_test)
           accuracy_score(y_test, y_pred)
Out[14]: 0.91333333333333333
In [15]: plt.figure(figsize=(18, 8))
           plt.subplot(121)
           plot_decision_boundary(k_neigh, X, y)
plt.title('KNeigbors, k=5', fontsize=14)
           plt.subplot(122)
           plot_decision_boundary(k_best_n, X, y)
           plt.title("KNeigbors, k=7", fontsize=14)
           plt.show()
                                      KNeigbors, k=5
                                                                                                       KNeigbors, k=7
               1.5
               1.0
                                                                                1.0
               0.5
                                                                                0.5
             x_2
                                                                             X<sub>2</sub>
              -1.0 <del>|</del>
-1.5
                                                                               -1.0 <del>|</del>
-1.5
                                            XI
                                                                                                             X<sub>1</sub>
```

GridSearchCV

Гит-репозиторий: https://github.com/llyagu/TMO